

퓨쳐누리 정보기술연구소

2014.07

# **CONTENTS**

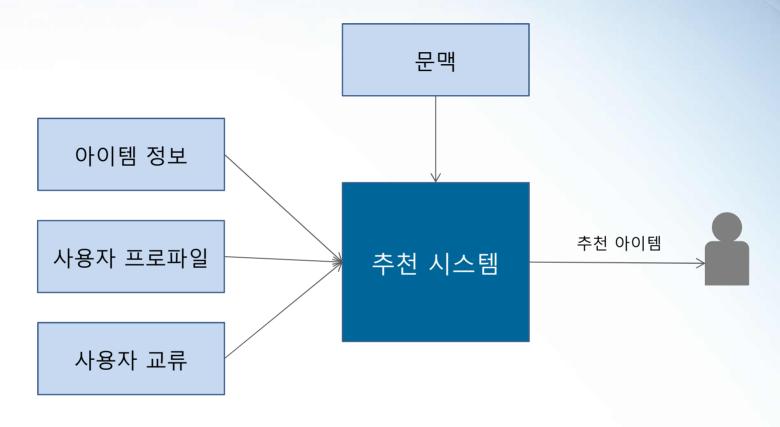
- 1 추천 시스템
- 2 협업 필터링
- 3 도서관 시스템 적용 사례
- 4 향후 연구 과제
- 5 질의응답



## 추천 시스템 (Recommender System)

- 정보기술과 인터넷의 발전으로 디지털 정보의 폭발적인 증가
- 정보과잉에 따른 정보의 선택이 필요
- 이용자가 원하는 정보를 효율적으로 이용할 수 있도록 검색 또는 여과하는 일을 수행하는 시스템
- 최근 다양한 분야의 어플리케이션에 적용되고 있음
  - 영화, 음악, 뉴스, 도서, 연구논문, 검색어, 태깅, 각종 제품들, ...

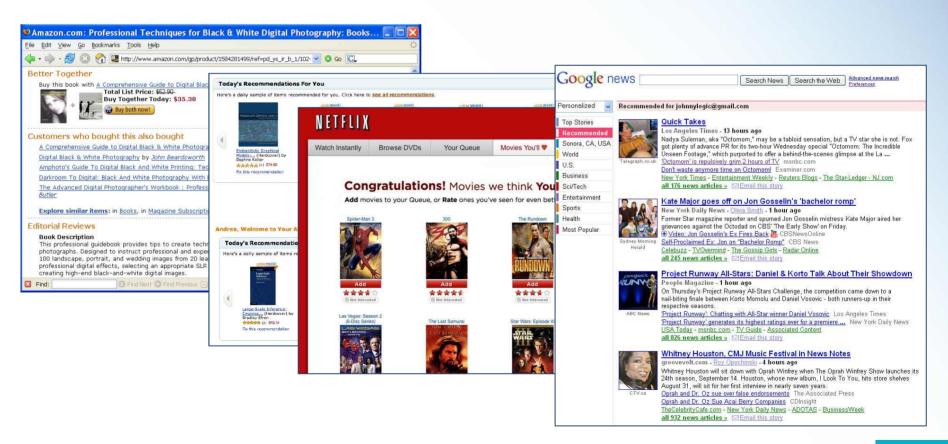
## 추천 시스템의 입력과 출력



- 사용자 프로파일 나이, 성별, 사는 곳, 자산 등
- 아이템 정보 아이템과 관련된 콘텐츠
- 사용자 교류 등급, 태깅, 북마킹, 저장, 이메일 사용 내역, 콘텐츠 열람 여부
- 문맥 아이템이 보여질 문맥, 문맥에 매칭하기 위해 고려될 아이템들의 하위 카테고리

#### 추천 시스템 성공 사례

- Amazon : 판매의 35%가 추천으로 부터 발생
- Netflix : 대여되는 영화의 2/3가 추천으로 부터 발생
- Google News : 38% 이상의 조회가 추천에 의해 발생



#### 도서 추천 서비스의 예

- 아마존과 같은 인터넷 도서 판매 사이트에서는 고객들의 구매 패턴을 이용하여 연 관성이 있는 도서를 추천
- 아마존의 데이터베이스에 포함된 메타데이터인 책 제목, 저자, 장르, 사용자 코멘트, 개요 등의 정보를 분석하여 사용자에게 도서를 추천
- 알라딘 서점의 '이책을 구입하신 분들이 다음 책도 구입하셨습니다."



#### 추천을 위한 접근방법들

- 협업 필터링 (Collaborative Filtering)
  - 사용자의 평가 내역을 이용
  - User-based, Item-based
  - 다양한 범위의 추천 가능, 많은 자료를 필요로 함
  - cold-start, scalability, sparsity 문제점을 가지고 있음
- 내용 기반 필터링 (Content-based Filtering)
  - 사용자 혹은 상품의 내용을 이용
  - Natural Language Processing, Information Retrieval 등 분야의 기법을 사용
  - 예) 영화의 설명을 참고하여 유사한 영화를 추천
  - 적은 자료로 추천 가능하나 추천 범위가 좁음
- 하이브리드 추천 시스템 (Hybrid Recommender System)
  - Collaborative Filtering + Content-based Filtering
  - 몇몇의 경우에 더 효과적
  - 대표적인 예 : Netflix
  - cold-start, sparsity 문제의 극복을 위해 사용되기도 함

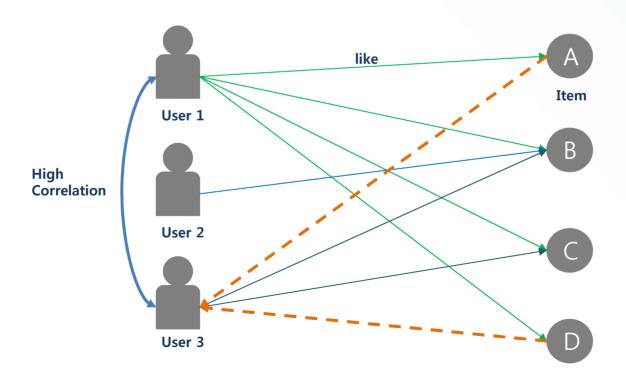


# 협업 필터링 (Collaborative Filtering)

- 추천시스템에서 추천을 을 위한 접근방법 중의 한가지
- "많은 사용자들로부터 얻은 기호정보(taste information)에 따라 사용자들의 관심 사들을 자동적으로 예측하게 해주는 방법" - Wikipedia.
- 사용자들의 과거의 경향이 미래에서도 그대로 유지 될 것이라고 가정
- 고객들의 선호도와 관심 표현을 바탕으로 선호도, 관심에서 비슷한 패턴을 가진 고객들을 식별해 내는 기법
- 사용자 기반 필터링 (User Based Collaborative Filtering)
- 아이템 기반 필터링 (Item Based Collaborative Filtering)

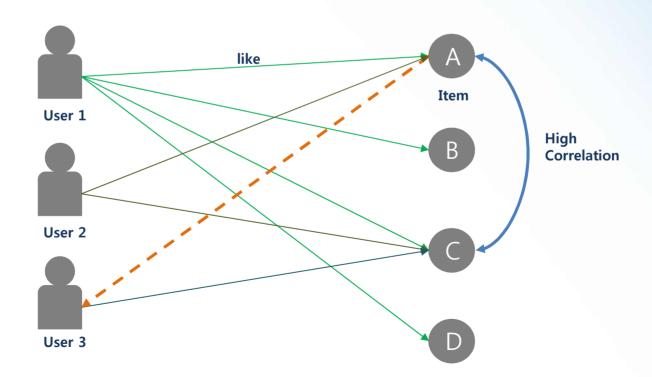
## 사용자 기반 (User Based Collaborative Filtering)

- 비슷한 선호도를 가지는 다른 고객들의 상품에 대한 평가에 근거하여 추천
- 우선 비슷한 성향을 가진 이웃을 찾고, 그 이웃의 선호도를 이용
- 이웃을 선정하는 방법은 유사도 계산 알고리즘을 이용
- 두 고객이 모두 평가를 한 상품이 있어야 하고, 오직 두 고객 사이에서만 상관 관계를 구할 수 있는 제약이 있음



## 아이템 기반 (Item Based Collaborative Filtering)

- 사람들이 과거에 좋아했던 상품과 비슷한 상품을 좋아하는 경향이 있는 것을 기 반으로 함
- 고객이 선호도를 입력한 기존 상품들과, 예측 하고자 하는 상품과의 유사도를 계산하여 선호도를 측정
- 고객들의 선호도만을 이용하기 때문에 고객간의 유사도는 고려되지 않음



#### 협업필터링을 이용한 아이템 추천 과정

- 단계 1 : 표현 작업 (Representation)
  - 이용자가 평가했던 아이템을 이용하여 모형화 하는 단계
- 단계 2 : 이웃 형성 (Nearest Neighborhood)
  - 유사한 이웃을 식별하기 위한 단계
- 단계 3 : 추천 생성 (Generation of Recommendation)
  - 특정 이용자에게 다른 이용자가 평가한 아이템을 추천하는 단계



#### 단계 1: 표현 작업

- 이용자가 평가했던 아이템을 이용하여 모형화 하는 단계
- 이용자 m 명과 아이템 n개의 선호도 집합
- 이용자-아이템 행렬로 표현 (R = m x n)
- 행렬의 각 성분값은 선호도의 값
  - 명시적 평가 (explicit ratings)
  - 암묵적 평가 (implicit ratings)

Table 1: The representation matrix  $m \times n$ 

$m \times n$	Item 1	Item 2	Item 3	Item 4	Item 5	Item 6
	Pringles	Rafaello	Snickers	Cola	Pepsi	Napoleon
User 1: John	1	5		2	4	?
User 2: Alex	4	2		5	1	2
User 3: Yngve	2	4	3			5
User 4: Lars	2	4		5	1	

http://recommender.no/representation-step-recommender-algorithms/

#### 단계 2: 이웃 형성

- 유사한 이웃을 식별하기 위한 단계
- 각각의 이용자에 대해 순위화된 이용자 리스트를 찾는 것
- 추천시스템 알고리즘
  - 이웃형성 과정을 통해 모형을 만들거나 학습하는 과정
- 이웃집단을 형성하기 위한 단계
  - 유사도 계산 알고리즘을 통해 특정 이용자와 모든 다른 이용자 사이의 유사 도를 구한다
  - 이웃 집단의 규모를 결정 (몇 명의 이용자를 이용할지 결정)
- 이웃집단의 규모를 결정하는 방법
  - 특정 가중치 이상인 이용자(Thresholding)
  - 가중치 기준 상위 M명의 이용자 (Best-n-neighborhood)

### 유사도 계산 알고리즘

- 유클리디안(Euclidean) 거리 점수 기반
- 코사인(Cosine) 기반
- 자카드 계수 (Jaccard) 기반
- 피어슨 상관계수
- 맨해튼 거리
- •

#### 단계 3: 추천 생성

- 특정 이용자에게 다른 이용자가 평가한 아이템을 추천하는 단계
- 이웃 집단으로 부터 상위 N개의 아이템을 추출하여 순위화
- 순위화 방법은 척도에 따라 다름
  - 단순 빈도를 기준
  - 추천할 아이템에 대한 특정 이용자의 예측 선호도 값의 정렬
- 예측 선호도 구하는 방법
  - 특정 아이템에 대한 모든 이용자의 선호도를 가중평균하여 계산

## 협업 필터링 기법의 장점

- 내용이 어떤 형태로 되어 있든 정보를 검색할 수 있다
- 개인화된 추천을 제공할 수 있다
- 이용자가 검색하고자 하는 내용을 포함하지는 않지만 이용자에게 가치 있는 아이템을 추천할 수 있다

#### 협업 필터링 기법의 단점

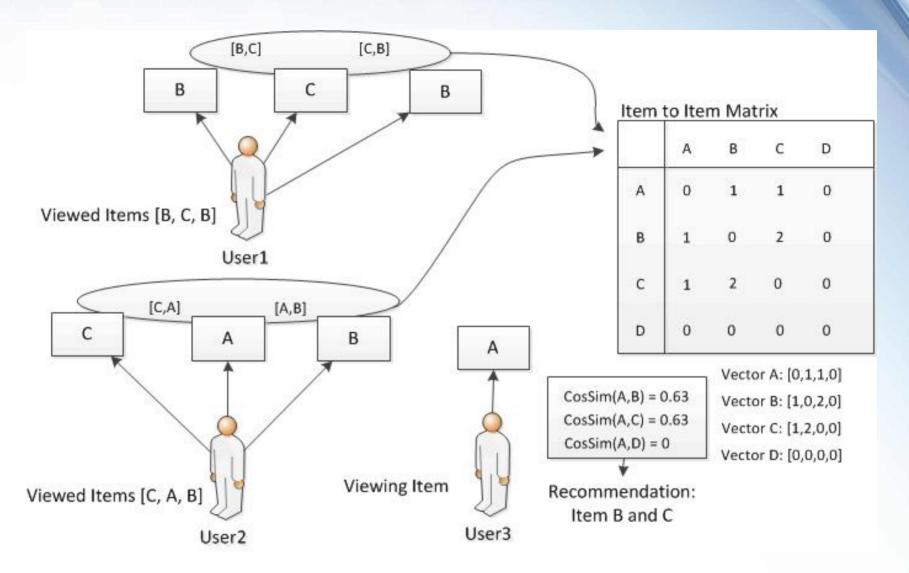
- 초기 평가자 문제 (Cold start)
  - 새로운 아이템이 추가되면 누군가가 선호도를 입력하거나 이용하기 전에 그
    아이템을 추천할 수 없는 문제
- 희소성 문제 (Sparsity)
  - 다수의 아이템에 대해 모든 이용자가 평가할 수 없기에 이용자-아이템 행렬의 평가 값들은 매우 희박한 상태가 됨
- 확장성 문제 (Scalability)
  - 고객과 거래 데이터가 증가함에 따라 유사한 고객군을 찾기위한 연산량이 기하급수적으로 증가하는 현상이 발생

#### **Amazon.com Item-to-item Collaborative Filtering**

- 상품 대 상품 (Item-to-Item) 관계를 이용하여 추천하는 방식
  - 개인의 성향은 중요하지 않음, 전체 사용자들의 패턴이 중요
- 추천에 필요한 상품과 상품의 관계를 미리 계산해 둠
- 사용자가 Item A를 보고 있을 때, A와 item-to-Item 관계성이 높은 상품 B,C,D를 즉시 추천
- 알고리즘

For each item in product catalog, *I1*For each customer *C who purchased I1*For each item *I2 purchased by*customer *C*Record that a customer purchased *I1* and *I2*For each item *I2*Compute the similarity between *I1 and I2* 

### **Amazon.com Item-to-item Collaborative Filtering**



출처 : http://kunuk.wordpress.com/2012/03/04/how-does-the-amazon-recommendation-system-work-analyze-the-algorithm-and-make-a-prototype-that-visualizes-the-algorithm/and-make-a-prototype-that-visualizes-the-alg



## 적용 시스템 개요

- 협업 필터링 기법 이용 도서 추천
- Item Based Collaborative Filtering
- 아파치 머하웃 (Apache Mahout)의 협업필터링 라이브러리인 Taste Package 이용
- 아이템간 유사도 계산은 로그우도 기반 유사도 계산 알고리즘 (Log-likelihood Similarity) 이용
- 선호도 자료는 최근 도서 대출 로그 300만건 이용
- 1회/1일 학습 후 추천자료 생성
- 학습 및 추천에 요구되는 자원 및 성능을 고려하여 별도의 시스템으로 구축
- 도서관 홈페이지(TULIP WEB)와 오픈API 형태로 연계하여 추천자료 제공

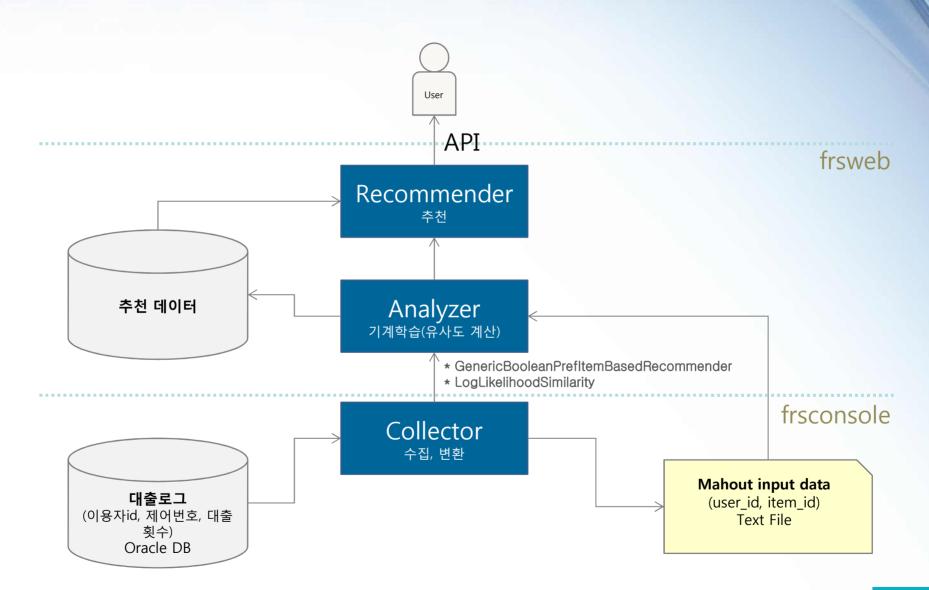
## 아파치 머하웃 (Apache Mahout)

- 아파치 소프트웨어 재단의 한 프로젝트
- 분산처리가 가능하고 확장성을 가진 기계학습용 라이브러리
- 비슷한 특성을 가진 데이터를 분류하고 정의하는 작업 및 협업필터링을 수행
- 머하웃(Mahout)의 사전적 의미는 '코끼리를 부리는 사람'
- 머하웃의 목표
  - 전통적인 기계학습 알고리즘을 효율적이고 확장 가능하도록 구현하고 대용량 데이터 처리가 가능하도록 하둡(Hadoop) 위에서 동작할 수 있게 알고리즘을 개선하는 것
- 머하웃의 핵심 테마
  - 추천엔진(협업 필터링), 군집, 분류





## 적용 시스템 구성도



## 선호도 자료

- 최근 도서 대출 로그
- 이용자ID, 서지 제어번호 항목으로 구성
- 학습대상 자료건수 : 300만건
  - 추천 성능에 영향을 주는 특정 자료실 제외
  - 딸림자료 대출 제외
  - 대출자수 2인 미만인 자료 제외

## 수집변환기(Collector)

- LAS의 집계데몬이 1회/1일 대출로그를 제어번호 기준으로 집계 / 저장
- 추출 조건에 따라 대출로그 집계자료 추출
- 머하웃용 입력자료로 변환 (String -> long형 변환, 일련번호 생성)
- 텍스트 파일 포맷으로 저장
- 수집변환이 완료되면 분석기 및 추천기를 재구동

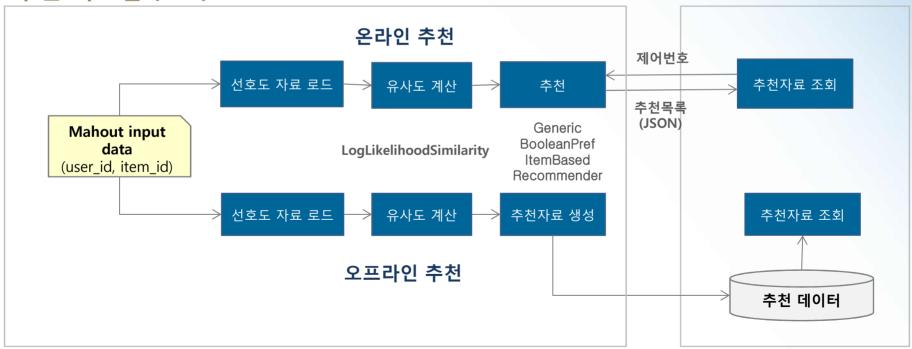
#### 도서관 자동화 시스템 (TULIP LAS) 추천 시스템 (FRS) 집계데몬 추출 변환 저장 (1회/1일) • 제어번호: String -> long 형 변환 • 이용자ID : long 형 일련번호 생성 대출로그 대출로그 집계 Mahout input data (날짜, 이용자id, 등록번호, (날짜, 이용자id, 제어번호, user\_id(long) 대출횟수) item id(long) **Oracle RDBMS Text File**

## 분석기(Analyzer)

- 머하웃용 선호도 파일을 입력자료로 로드
- LoglikelihoodSimilarity로 유사도 계산
- GenericBooleanPrefItemBasedRecommender로 추천자료 생성 / 추천
- 오프라인 방식: 추천자료를 미리 생성하고 홈페이지에서 직접 조회
- 온라인 방식 : 추천기를 통해 실시간 추천서비스

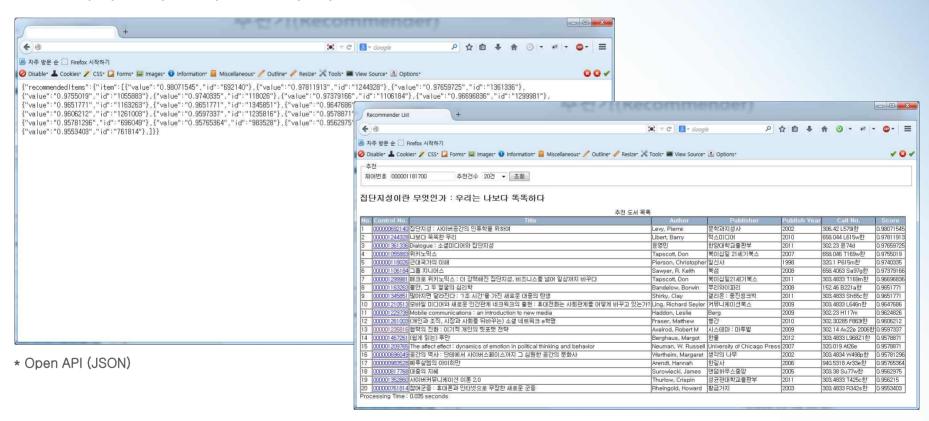
도서관 홈페이지 (TULIP WEB)

#### 추천 시스템 (FRS)



## 추천기(Recommender)

- Analyzer에 의해 생성된 유사도 계산 결과를 이용하여 추천
- Open API 방식으로 도서관 홈페이지 서지상세와 연계
  - 제어번호를 입력 파라메타로, 추천목록은 JSON 포맷으로 제공
- 관리자용 추천자료 조회 화면

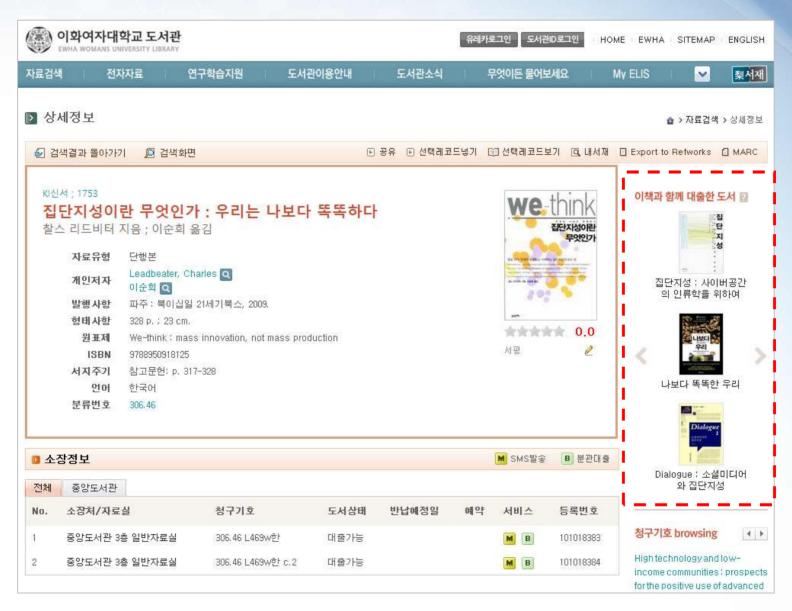


\* 관리자용 추천 자료 조회 화면

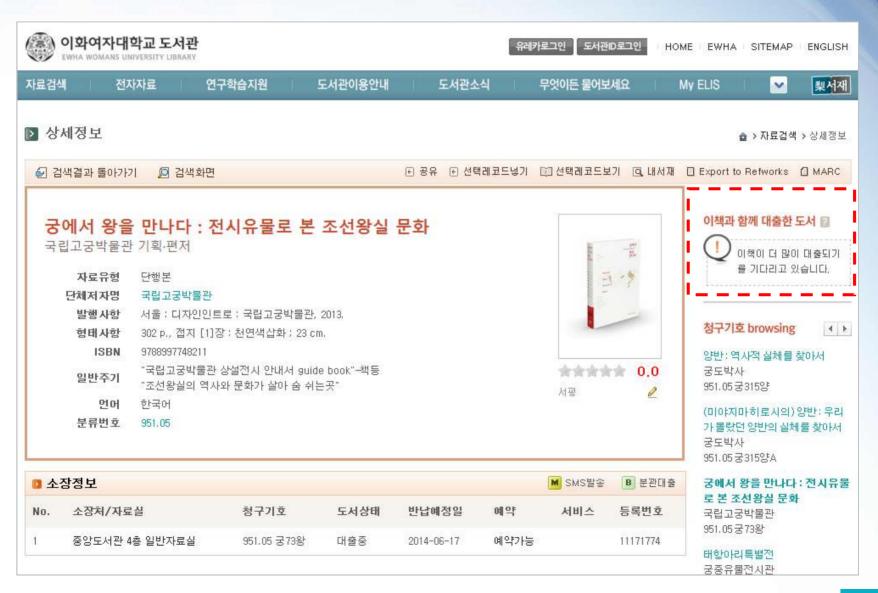
## 서비스 화면 (1)



## 서비스 화면 (2)



## 서비스 화면 (3)





## 향후 연구 과제

- 본 시스템 에서 제공하는 추천 데이터 활용도 조사 및 분석
- 도메인 특화정보 추가 분석 (IDRescorer)을 통한 추천 성능 개선
  - 주제분야, 이용자 속성, 아이템 속성
- 이용자 기반 추천 서비스 구현 및 아이템 기반 추천 서비스와 비교 분석
- 서지상세 뷰 기준 추천 구현 및 대출기준 추천과의 비교분석
- 추천 서비스 확장
  - 개인 서재의 도서 목록을 이용한 도서 추천 서비스
  - 태그 정보를 이용한 태그, 도서 추천 서비스
  - 서평 정보를 이용한 도서 추천 서비스
  - 검색어 로그를 이용한 검색어 추천 서비스
  - 게시물 정보를 이용한 게시판 게시물 추천 서비스

## 참고자료

- 1. Greg Linden, "Amazon.com Recommendations: Item-to-item Collaborative Filtering", Internet Computing, IEEE, 2003.
- 2. 정영미, "필터링 기법을 이용한 도서 추천 시스템 구축", 정보관리연구, Vol.33, No.1, 2002.
- 3. 윤종완, "집단지성 프로그래밍", 한빛미디어, 2008.
- 4. 전희원, "실전예제로 살펴보는 집단지성 프로그래밍", 인사이트, 2011.
- 5. 안태성, "머하웃 완벽 가이드", 한빛미디어, 2012.
- 6. http://www.slideshare.net/pitzcarraldo/mahout-cook-book
- 7. http://en.wikipedia.org/wiki/Recommender\_system
- 8. http://rosaec.snu.ac.kr/meet/file/20120728b.pdf
- 9. http://www.cimerr.net/board/view.php?id=iemagazine2&no=274
- 10. http://ko.wikipedia.org/wiki/협업\_필터링
- 11. http://kunuk.wordpress.com/2012/03/04/how-does-the-amazon-recommendation-system-work-analyze-the-algorithm-and-make-a-prototype-that-visualizes-the-algorithm/

